

# **Selección de características y modelos predictivos para el diagnóstico clínico mediante ultrasonido**



**Universidad**  
**Zaragoza**

**Samuel García García**  
Trabajo de fin de grado de Matemáticas  
Universidad de Zaragoza

Director del trabajo: Zeus Gracia Tabuenca  
11 de Junio de 2025



# Agradecimientos

Quiero expresar mi agradecimiento a todas las personas que han contribuido al desarrollo de este trabajo. En primer lugar, dar las gracias a mi tutor, Zeus Gracia Tabuenca, por su orientación, disponibilidad y apoyo constante a lo largo de todo el proceso de elaboración de este proyecto, así como por haberme proporcionado los conocimientos necesarios para afrontarlo con rigor.

También deseo agradecer a los investigadores Miguel Malo Urrié, Elena Bueno Gracia e Izarbe Ríos Asín, responsables del desarrollo de la herramienta *UZqTool*, por darme la posibilidad de trabajar con ella, facilitando los datos y las recomendaciones necesarias para completar este trabajo. Así mismo, agradecer a todos los pacientes que aceptaron participar en el estudio, cuya colaboración ha sido esencial para la realización de este trabajo.

Extiendo también mi agradecimiento a la Universidad de Zaragoza y al Grado de Matemáticas, incluyendo a todos los profesores que me han acompañado a lo largo de estos años, por brindarme la formación necesaria no solo para afrontar este proyecto, si no también para dar el próximo paso hacia mi desarrollo profesional.

Finalmente, agradecer a mi familia, que me ha estado apoyando de forma incondicional durante todos los años de mi etapa académica. Sin ellos, nada de esto habría sido posible.

# Resumen

El síndrome del túnel carpiano (STC) es una neuropatía causada por la compresión del nervio mediano al pasar por el túnel carpiano. El estándar actual para su diagnóstico se basa en estudios electrofisiológicos, como la electromiografía (EMG) y la velocidad de conducción nerviosa (VCN), que evalúan el estado funcional del nervio. Aunque precisos, estos métodos son invasivos, costosos y no siempre están disponibles en todos los entornos sanitarios. Como consecuencia, se están desarrollando herramientas diagnósticas alternativas. En este trabajo, se estudia el poder predictivo de la ecografía cuantitativa proporcionada por la herramienta *UZqTool* como método complementario o sustitutivo para el diagnóstico de casos graves de STC.

Se llevó a cabo un estudio prospectivo, unicéntrico y diagnóstico ciego, utilizando datos recogidos de cincuenta pacientes del Hospital Clínico Universitario Lozano Blesa. Se obtuvieron un total de noventa y cuatro observaciones de sus muñecas, clasificándolas, en base a las pruebas electrodiagnósticas, en cuatro categorías: sana, leve, moderada o grave, siendo esta última la indicadora de intervención quirúrgica. Como parte del análisis, la variable diagnóstico se transformó en un clasificador binario, tomando exclusivamente la categoría grave como positiva. Junto a cinco variables electrodiagnósticas, se extrajeron ochenta y ocho características de ecografía cuantitativa utilizando *UZqTool*, cuyos valores se obtienen mediante técnicas como la matriz de co-ocurrencia de niveles de gris (GLCM), estadísticas de diferencia de niveles de gris (GLDS) y la transformada de Haar, derivados de imágenes obtenidas por ecografías transversales y longitudinales del nervio mediano.

Dado el elevado número de predictores y la baja cantidad de observaciones, se realizó una selección de variables mediante regularización Lasso, combinada con validación cruzada *leave-one-out*. Posteriormente, se contruyeron distintos modelos de regresión logística utilizando las variables seleccionadas, evaluando el rendimiento de los modelos mediante la curva ROC y su área bajo la curva.

Entre los modelos basados en ecografía, el mayor rendimiento se obtuvo con el modelo de regresión logística construido con variables extraídas de imágenes longitudinales, cuyo AUC alcanzó un valor de 0,8019. En comparación con el modelo con variables electrodiagnósticas, cuyo AUC fue de 0,8979, el ultrasonido cuantitativo mostró una alta capacidad predictiva.

Aunque los resultados obtenidos no muestran que se pueda sustituir por completo el estándar actual, estos refuerzan la viabilidad y posibilidad de la futura integración del ultrasonido cuantitativo en la práctica clínica.

# Abstract

Carpal tunnel syndrome (CTS) is a prevalent neuropathy caused by compression of the median nerve as it passes through the carpal tunnel in the wrist. The current standard for diagnosis is based on electrodiagnostic studies, such as electromyography (EMG) and nerve conduction velocity (NCV), which assess the functional state of the nerve. While accurate, these methods are invasive, costly, and not always available in all healthcare settings. As a result, there is growing interest in alternative, non-invasive diagnostic approaches. This study investigates the predictive power of quantitative ultrasound (QUS) provided by *UZqTool* as a complementary or substitute tool for diagnosing severe cases of CTS.

A prospective, single-center, blinded diagnostic study was conducted using data collected from fifty patients at the Hospital Clínico Universitario Lozano Blesa. A total of ninety four wrist observations were obtained, and each one was classified into four diagnostic categories based on electrodiagnostic testing: healthy, mild, moderate or severe, the last of which is considered an indicator for surgical intervention. As part of the analysis, the diagnosis variable was transformed into a binary classifier, where only severe cases were considered positive. Alongside five electrodiagnostic variables, eighty eight quantitative ultrasound features were extracted using *UZqTool*, which computes quantitative parametres using techniques such as gray-level co-occurrence matrix (GLCM), gray-level difference statistics (GLDS) and Haar wavelet, derived from transverse and longitudinal ultrasound images of the median nerve.

Given the high dimensionality of the ultrasound and the limited number of observations of the dataset, feature selection was performed using Lasso regularization in combination with leave-one-out cross validation. Logistic regression models were subsequently built using the most frequently selected variables. Additionally, model performance was evaluated using ROC curve and its area under the curve (AUC).

Among ultrasound-based models, the best performance was achieved by a logistic regression model derived from longitudinal ultrasound features selected by a previous Lasso model, which reached an AUC of 0,8019. In comparison with the reference electrodiagnostic model, which has an AUC of 0,8979, quantitative ultrasound showed potential in detecting severe CTS cases with hight predictive reliability.

Overall, this work highlights the viability of quantitative ultrasound as a diagnostic tool in clinical settings. Although it does not fully replace traditional electrodiagnosis, the result reached support on its clinical integration and could be validated with external datasets in order to consolidate QUS in clinical practice.

# Índice general

<b>Agradecimientos</b>	<b>III</b>
<b>Resumen</b>	<b>IV</b>
<b>Abstract</b>	<b>V</b>
<b>1. Introducción</b>	<b>1</b>
1.1. Descripción del problema . . . . .	1
1.2. Objetivos . . . . .	2
<b>2. Metodología</b>	<b>3</b>
2.1. Datos . . . . .	3
2.2. Modelos lineales . . . . .	3
2.2.1. Estimación . . . . .	4
2.3. Regresión logística . . . . .	5
2.3.1. Estimación . . . . .	5
2.4. Métodos de regularización . . . . .	6
2.4.1. Lasso ( <i>least absolute shrinkage and selection operator</i> ) . . . . .	6
2.4.2. Red elástica . . . . .	6
2.5. Validación . . . . .	7
2.5.1. Validación cruzada . . . . .	7
2.6. Métodos de muestreo . . . . .	7
2.7. Evaluación . . . . .	8
2.8. Código empleado . . . . .	10
<b>3. Resultados</b>	<b>11</b>
3.1. Modelo electrodiagnóstico . . . . .	11
3.2. Modelos con variables ecográficas . . . . .	12
3.2.1. Modelo Completo . . . . .	12
3.2.2. Modelo Transversal . . . . .	14
3.2.3. Modelo Longitudinal . . . . .	15
3.2.4. Modelos de red elástica . . . . .	16
<b>4. Discusión</b>	<b>18</b>
<b>Bibliografía</b>	<b>20</b>
<b>Apéndice</b>	<b>21</b>

# Capítulo 1

## Introducción

### 1.1. Descripción del problema

El síndrome del túnel carpiano (STC) es una neuropatía causada por la compresión del nervio mediano a su paso por el túnel carpiano, localizado en la muñeca, cuyos síntomas incluyen dolor, entumecimiento y hormigueo en la mano (MedlinePlus, 2023a).

El diagnóstico estándar de esta patología se basa en estudios de conducción nerviosa (ECN), como la electromiografía (EMG) y la velocidad de conducción (VCN). En la EMG, se introduce un electrodo de aguja que evalúa la actividad eléctrica del músculo en respuesta a la estimulación del nervio (MedlinePlus, 2024b). Paralelamente, se estudia la VCN, donde se dispone de electrodos de superficie colocados sobre la piel. Se aplican impulsos eléctricos y se mide el tiempo que tardan en viajar entre los electrodos, permitiendo así calcular la velocidad de conducción de las señales nerviosas (MedlinePlus, 2023b). A partir de estos estudios, se obtienen dos variables sensoriales y tres motoras, siendo estas últimas las más afectadas en los casos graves de STC. No obstante, estas pruebas presentan diversas limitaciones, tales como su carácter invasivo, su alto coste y la disponibilidad restringida de los centros de salud, lo que dificulta el diagnóstico y tratamiento del STC.

Como consecuencia, la ecografía mediante ultrasonido ha surgido como alternativa de diagnóstico no invasiva que permite evaluar la estructura del nervio mediano. En ella, se utilizan ondas sonoras para generar imágenes de los tejidos nerviosos, permitiendo visualizar el interior del cuerpo sin necesidad de cirugía (MedlinePlus, 2024a). Sin embargo, la precisión de la ecografía convencional está influenciada por la variabilidad del operador y la falta de estandarización en los criterios de medición. Para abordar estos inconvenientes, se han desarrollado herramientas de ultrasonido cuantitativo que permiten una evaluación más objetiva mediante el análisis de características.

En concreto, la herramienta *UZqTool* analiza los píxeles de las imágenes obtenidas en la ecografía seleccionando manualmente cuatro regiones de interés del tendón: la calidad del tejido, los bordes superior e inferior y el grosor. En la figura 4.1 se ejemplifica cómo se lleva a cabo dicha selección de las regiones de interés en el caso del tendón rotuliano. Para cada uno de estos módulos, se obtienen un conjunto de variables cuyos valores se calculan mediante técnicas de análisis de textura, como la matriz de cocurrencia de grises (GLCM), estadísticas de diferencias de niveles de gris (GLDS) y la ondícula de Haar. Esta herramienta fue probada previamente en un estudio piloto con catorce participantes para el diagnóstico en lesiones del tendón rotuliano. Los análisis que se realizaron mostraron una alta fiabilidad en ciertas variables cuantitativas obtenidas por *UZqTool*, reforzando su utilidad como método objetivo y reproducible para la evaluación clínica (Albarova-Corral et al., 2024).

Otras herramientas han sido desarrolladas previamente para el diagnóstico del STC. En el artículo Chen et al. (2021), se evalúa la eficacia de la ecografía cuantitativa en el diagnóstico del STC. En este estudio, se comparan resultados obtenidos mediante estudios electrodiagnósticos con parámetros ecográficos, como el área de sección transversal (CSA), y la diferencia ( $\Delta$ CSA) y el cociente (WFR) entre los CSA del nervio mediano en el túnel carpiano y en el antebrazo. A pesar de que la ecografía mostró una elevada precisión diagnóstica, tomando valores CSI (índice de éxito crítico) superiores a 0,9, su capaci-

dad para clasificar la gravedad del síndrome, obteniendo un estadístico C de entre 0,64 y 0,661, resultó limitada. En cambio, estudios más recientes han incorporado inteligencia artificial y *machine learning*. En particular, en el artículo Kim et al. (2023), se explora la aplicación de modelos radiómicos y algoritmos de aprendizaje automático, como el *support vector classifier* (SVC), combinado con técnicas de selección de características. Con una muestra de setenta y cuatro muñecas, los resultados evidenciaron una alta fiabilidad predictiva, obteniendo un AUC de 0,89.

## 1.2. Objetivos

El objetivo principal de este estudio es evaluar el carácter predictivo del ultrasonido cuantitativo en el diagnóstico del síndrome del tunel carpiano. Con el fin de obtener resultados sólidos y clínicamente significativos, el estudio se plantea con una metodología en tres fases.

En primer lugar, se lleva a cabo un proceso de selección de las características de un amplio conjunto de variables ecográficas. Este paso permite reducir la complejidad del modelo y enfocarse en las variables con mayor poder predictivo. Dado el elevado número de predictores, los métodos tradicionales de selección de variables no son de utilidad. En consecuencia, se aplican métodos regularizados como Lasso y red elástica, con el fin de obtener los predictores más relevantes.

Posteriormente, se construyen los correspondientes modelos logísticos clásicos que relacionan las variables seleccionadas anteriormente con la probabilidad de que un paciente padezca la patología.

Finalmente, se comparan las capacidades predictivas de todos los modelos construidos, buscando el que posea mayor rendimiento. Esta evaluación incluye métricas de rendimiento, como el cálculo del área bajo la curva ROC. Además, se lleva a cabo un análisis comparativo del mejor modelo ecográfico con los estudios de conducción nerviosa, cuya finalidad es determinar la superioridad o complementariedad del ultrasonido cuantitativo.

Este enfoque busca no solo evaluar la eficacia del modelo propuesto, sino también explorar la viabilidad de incorporar el ultrasonido cuantitativo en la práctica clínica habitual.

# Capítulo 2

## Metodología

### 2.1. Datos

Para el diseño del conjunto de datos, se llevó a cabo un ensayo prospectivo, unicéntrico y diagnóstico ciego con pacientes del Hospital Clínico Universitario Lozano Blesa. El estudio fue aprobado por el Comité de Ética de Aragón (C.I. PI23-440 y PI23-437) y todos los pacientes fueron informados de los objetivos del estudio, la metodología y los potenciales riesgos antes de su inclusión. Los datos se han anonimizado antes del análisis y a cada participante se le dio la opción de retirarse del estudio en cualquier momento.

La muestra está compuesta por 50 pacientes, con un rango de edad entre 22 y 90 años cuya media es de 56 años, de los cuales el 74 % son mujeres. A cada uno de ellos se le evaluó una o ambas muñecas, consideradas como unidades independientes dado que no hay correlación bilateral en la presentación de esta patología, obteniendo un número total de 94 observaciones. En las extremidades analizadas, se recogió una variable diagnóstico, evaluada en una escala de 0 a 3. Esta valoración fue realizada por un neurofisiólogo, ciego al resto de evaluaciones con fin de evitar sesgos, utilizando las pruebas de estimulación del nervio mediano (ECN), cuyos valores se conservaron en cinco variables. A partir de estas pruebas, se clasificó cada muñeca como normal, leve, moderada o severa, siendo esta última indicativa de necesidad de intervención quirúrgica. En la base de datos, las proporciones correspondientes a cada categoría diagnóstica son del 32 %, 36 %, 14 % y 18 % respectivamente. Para este trabajo, se recodificó la variable diagnóstico como binaria, asignando un valor de 0 a los casos clasificados como normales, leves y moderados; y un valor de 1 a los severos, dado que el objetivo es priorizar la detección de los casos más graves. La proporción de esta nueva variable es de 82 % muñecas sanas frente a un 18 % de muñecas que presentan la patología.

Además de las cinco variables de electrodiagnóstico, se tienen ochenta y ocho variables cuantitativas de ultrasonido proporcionadas por la herramienta *UZqTool*. Cada paciente se sometió a ecografías longitudinales y transversales del nervio mediano, realizadas por un único examinador y parámetros estandarizados para garantizar la consistencia entre pacientes. Las imágenes ecográficas se analizaron con *UZqTool* que, mediante algoritmos avanzados de procesamiento de imágenes (GLDS, GLCM y Haar), genera unidades arbitrarias de forma e intensidad. De esta manera, obtenemos una cuantificación detallada de los parámetros de ultrasonido correspondientes a la calidad, los bordes y la morfología del nervio, tanto para las ecografías longitudinales como transversales. La lista de variables obtenidas por la herramienta para cada región de interés se muestra en la tabla 4.1.

### 2.2. Modelos lineales

Sean las variables aleatorias independientes  $y_i$  ( $i = 1, \dots, n$ ), normalmente distribuidas y de varianza constante  $\sigma^2$ . Para cada observación  $i$ , consideramos los valores  $\{x_{ij}\}_{j=1}^p$  de variables predictoras conocidas. El modelo de regresión lineal general tiene la forma

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \varepsilon_i, \quad (2.1)$$

donde  $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ . Tanto  $\beta_j$  como  $\sigma$  son parámetros desconocidos que debemos estimar.

En notación matricial, el modelo se escribe como

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (2.2)$$

donde

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{np} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_n \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix},$$

(Galecki & Burzykowski, 2013).

### 2.2.1. Estimación

En los modelos lineales, lo más común para hallar los valores estimados de  $\beta_i$  y  $\sigma^2$  es el método de mínimos cuadrados, sin embargo, esta técnica es menos apropiada para modelos más complejos. Por tanto, se va a introducir el método de máxima verosimilitud, que resultará de utilidad en la sección 2.3, donde se verá el modelo de regresión logística.

Puesto que  $\boldsymbol{\varepsilon} \sim \mathcal{N}(0, \sigma^2 I_n)$ , tenemos que  $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \sigma^2 I_n)$ . De esta forma, su función de verosimilitud es

$$L(\boldsymbol{\beta}, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - X_i\boldsymbol{\beta})^2}{2\sigma^2}\right),$$

donde  $X_i$  representa la fila  $i$ -ésima de la matriz  $\mathbf{X}$ .

Tomando el logaritmo de la función de verosimilitud,

$$\begin{aligned} l(\boldsymbol{\beta}, \sigma^2) &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - X_i\boldsymbol{\beta})^2 = \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^t (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}). \end{aligned}$$

Ahora, para encontrar el estimador de máxima verosimilitud  $\hat{\boldsymbol{\beta}}$ , se deriva la función con respecto a  $\boldsymbol{\beta}$  y se iguala a cero.

$$\begin{aligned} \frac{\partial l}{\partial \boldsymbol{\beta}} &= \frac{1}{\sigma^2} \mathbf{X}^t (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = 0 \\ \hat{\boldsymbol{\beta}} &= (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{Y}. \end{aligned}$$

Análogamente, para estimar la varianza  $\sigma^2$ , se deriva la función log-verosimilitud respecto a  $\sigma^2$ .

$$\begin{aligned} \frac{\partial l}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^t (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = 0 \\ \hat{\sigma}^2 &= \frac{1}{n} (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^t (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}). \end{aligned}$$

Este estimador es sesgado, pues al usar  $\hat{\boldsymbol{\beta}}$  perdemos  $p+1$  grados de libertad. Para obtener un estimador insesgado para la varianza, escribimos

$$\hat{\sigma}^2 = \frac{1}{n-p-1} (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^t (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}).$$

## 2.3. Regresión logística

El modelo de regresión logística es utilizado para la clasificación binaria. A diferencia de los modelos lineales, predice la probabilidad de que una observación pertenezca a una entre dos clases.

De forma análoga a lo expuesto en la sección 2.2, se considera la matriz de diseño  $\mathbf{X}$ , con  $n$  observaciones y  $p$  variables explicativas, y el vector de coeficientes del modelo  $\beta$ . De esta forma, para una variable  $Y \in \{0, 1\}$ , el modelo de regresión logística es de la forma

$$P(Y = 1 \mid \mathbf{X}) = f(\mathbf{X}\beta) = \frac{1}{1 + e^{-\mathbf{X}\beta}}, \quad (2.3)$$

donde  $f(z)$  representa la función logística (Kleinbaum & Klein, 2010).

### 2.3.1. Estimación

Para hallar el valor estimado de  $\beta$ , se emplea de nuevo el método de máxima verosimilitud. Teniendo en cuenta que

$$\begin{aligned} P(y_i = 1 \mid X_i) &= f(X_i\beta), \\ P(y_i = 0 \mid X_i) &= 1 - f(X_i\beta). \end{aligned}$$

La función de verosimilitud es

$$L(\beta) = \prod_{i=1}^n f(X_i\beta)^{y_i} (1 - f(X_i\beta))^{1-y_i}.$$

Tomando el logaritmo,

$$\begin{aligned} l(\beta) &= \sum_{i=1}^n [y_i \log f(X_i\beta) + (1 - y_i) \log (1 - f(X_i\beta))] = \\ &= \sum_{i=1}^n \{y_i [\log f(X_i\beta) - \log (1 - f(X_i\beta))] + \log (1 - f(X_i\beta))\} = \\ &= \sum_{i=1}^n \left( y_i X_i \beta + \log \left( \frac{1}{1 + e^{X_i \beta}} \right) \right). \end{aligned}$$

Derivando respecto a  $\beta$  e igualando a cero,

$$\nabla l = \frac{\partial \log L}{\partial \beta} = \sum_{i=1}^n X_i y_i - X_i \frac{e^{X_i \beta}}{1 + e^{X_i \beta}} = \sum_{i=1}^n X_i (y_i - f(X_i \beta)) = X^t (Y - P) = 0,$$

donde  $P$  es el vector  $n \times 1$  de probabilidades, es decir, sus elementos son de la forma  $p_i = f(X_i \beta)$ .

Este sistema de ecuaciones no tiene solución analítica. Para obtener el valor de los estimadores, se utiliza el método iterativo Newton-Raphson. Cada iteración tiene la expresión

$$\beta^{(t+1)} = \beta^{(t)} - H^{-1} \nabla l,$$

donde  $H$  es la matriz hessiana de  $l$ . Para su obtención, se calcula la derivada de segundo orden.

$$H = \frac{\partial^2 \log L}{\partial \beta \partial \beta} = - \sum_{i=1}^n X_i^t f(X_i \beta) (1 - f(X_i \beta)) X_i = -X^t P (1 - P) X.$$

De esta forma,

$$\beta^{(t+1)} = \beta^{(t)} + (X^t P (1 - P) X)^{-1} X^t (Y - P).$$

Ejecutando las iteraciones suficientes para que  $\beta$  converja, finalmente se obtiene

$$\hat{\beta} = \beta^{(t+1)} = \beta^{(t)} + (X^t P (1 - P) X)^{-1} X^t (Y - P).$$

## 2.4. Métodos de regularización

Los métodos de regularización son un conjunto de técnicas empleadas para corregir el sobreajuste en modelos *machine learning*. La regularización permite aumentar la capacidad de generalización del modelo, es decir, la capacidad predictiva a la hora de abordar nuevas bases de datos, a costa de perder precisión en el conjunto de entrenamiento.

Hay tres principales métodos de regularización, también llamados *shrinkage*: Lasso, *Ridge* y red elástica (Cleophas & Zwinderman, 2024).

### 2.4.1. Lasso (*least absolute shrinkage and selection operator*)

Lasso es un método de regularización cuyos coeficientes son obtenidos al resolver el problema de optimización

$$\hat{\beta} = \min_{\beta} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2,$$

sujeto a  $\sum_{j=1}^p \|\beta_j\|_1 \leq t,$

utilizando la misma notación que la empleada en 2.2.

Este problema puede ser reescrito a su equivalente forma Langraniana

$$\hat{\beta} = \min_{\beta} \left\{ \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p \|\beta_j\|_1 \right\}.$$

Como se observa, Lasso aplica una penalización a la norma uno de los coeficientes. Esta restricción provoca que las soluciones sean no lineales y, por consiguiente, que no haya una expresión explícita para ellos.

Esta penalización a los coeficientes también influye en que algunos se iguale a cero, obteniendo así un método de selección de variables.

En el caso de querer obtener un modelo Lasso logístico, en el problema de minimización se sustituye la expresión de los mínimos cuadrados por menos la función log-verosimilitud del modelo (2.3), cuya expresión ya ha sido obtenida en 2.3.1.

$$\hat{\beta} = \min_{\beta} \left\{ -l(\beta) + \lambda \sum_{j=1}^p \|\beta_j\|_1 \right\}.$$

Como ya se ha mencionado, la principal ventaja de Lasso es su capacidad para realizar selección de variables. Sin embargo, este método puede ser inestable para variables altamente correladas (Junior & Pereira, 2024).

### 2.4.2. Red elástica

La red elástica es un método de regularización estadística que combina los métodos Lasso y *Ridge*, agregando penalización tanto a la norma uno como a la dos de los coeficientes. La red elástica se utiliza en regresión lineal y logística para manejar problemas de sobreajuste y evitar multicolinealidad.

Para hallar los coeficientes, se resuelve el siguiente problema de optimización:

$$\hat{\beta} = \min_{\beta} \left\{ \frac{1}{2n} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \left( \alpha \sum_{j=1}^p \|\beta_j\|_1 + (1-\alpha) \sum_{j=1}^p \beta_j^2 \right) \right\},$$

donde  $\lambda$  es el único parámetro de regularización, mientras que  $\alpha \in [0, 1]$  controla el peso de las normas. De esta forma, cuando  $\alpha$  es cero, el método equivale al modelo *Ridge*, mientras que si es uno, se recupera el modelo Lasso como caso particular.

Análogamente a 2.4.1, para construir un modelo logístico regularizado por red elástica, se calculan los coeficientes resolviendo el siguiente problema:

$$\hat{\beta} = \min_{\beta} \left\{ -l(\beta) + \lambda \left( \alpha \sum_{j=1}^p \|\beta_j\|_1 + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right) \right\}.$$

A diferencia de Lasso, este método es más flexible pues combina las ventajas de Lasso y *Ridge*, lo que permite controlar mejor la colinealidad entre los predictores. No obstante, puede dar como resultado modelos más complejos, incluyendo variables cuyos coeficientes sean extremadamente bajos.

## 2.5. Validación

La validación es un procedimiento empleado para evaluar el desempeño de un modelo y determinar su capacidad de generalización ante la incorporación de nuevas observaciones. Existen dos enfoques principales: validación interna y externa. La validación interna utiliza los mismos datos con los que se construyó el modelo, permitiendo evaluar su ajuste, aunque sin garantizar una buena generalización. Por el contrario, la validación externa emplea observaciones no utilizadas en el proceso de entrenamiento del modelo, proporcionando una estimación más realista de su capacidad predictiva (Hastie et al., 2009).

### 2.5.1. Validación cruzada

La validación cruzada es uno de los métodos más simples y utilizados para estimar el error de predicción. Esta técnica permite aproximar el error esperado en datos externos, es decir, el error medio que se obtendría al aplicar el modelo a un conjunto de datos independiente del empleado en su ajuste. En situaciones ideales, se dispone de suficientes datos como para reservar un subconjunto de datos exclusivo para la validación del modelo. Sin embargo, esto no siempre es posible, lo que ha motivado el desarrollo de distintas variantes de validación cruzada.

La más común es la validación cruzada *K-Fold*, que consiste en dividir el conjunto de datos en  $K$  particiones de igual tamaño. En cada iteración, se toma la  $k$ -ésima parte y se ajusta el modelo con las  $K - 1$  restantes, calculando el error de predicción del modelo para dicha parte. Este proceso se realiza para  $k = 1, \dots, K$  y se combinan las  $K$  estimaciones del error de predicción.

Un caso particular es la validación cruzada *leave-one-out* (LOOCV), en la que  $K$  es igual al número de observaciones. En este caso se entrena el modelo dejando fuera una única observación en cada iteración, utilizando el resto como conjunto de entrenamiento (Hastie et al., 2009).

## 2.6. Métodos de muestreo

Los métodos de muestreo (*sampling methods*) son técnicas empleadas para hacer frente al desbalanceo de clases (*class imbalance*) en problemas de clasificación. Consisten en modificar la distribución de clases del conjunto de datos, generalmente aumentando la proporción de la clase minoritaria, con el objetivo de obtener un conjunto más equilibrado entre las categorías. Entre los métodos más comunes se encuentran: *undersampling*, *oversampling*, SMOTE y ROSE.

Las técnicas más sencillas son el *undersampling* y el *oversampling*. En el primer caso, se eliminan aleatoriamente observaciones de la clase mayoritaria en el conjunto de entrenamiento. Por el contrario, el *oversampling* consiste en la duplicación de instancias de la clase minoritaria. Si bien ambos métodos contribuyen a reducir el desbalanceo, no introducen nueva información, por lo que los problemas derivados de tener una clase minoritaria extremadamente escasa pueden persistir.

Por otro lado, SMOTE (*Synthetic Minority Over-sampling Technique*) y ROSE (*Random Over Sampling Examples*) son técnicas que sí generan nuevos datos de manera artificial. SMOTE crea nuevas observaciones de la clase minoritaria interpolando con sus vecinos más cercanos, introduciendo ejemplos no replicados pero coherentes con la distribución original. ROSE, en cambio, genera instancias de ambas categorías utilizando estimaciones de densidad local, produciendo datos aleatorios dentro de una vecindad previamente definida, manteniendo la estructura probabilística de los datos originales (Menardi & Torelli, 2012; Weiss, 2013).

## 2.7. Evaluación

Una vez construido un modelo, es imprescindible evaluar su desempeño para determinar su capacidad predictiva. Evaluar un modelo no consiste únicamente en comprobar si se ajusta bien a los datos de entrenamiento, si no en estimar cómo se comportará ante datos nuevos. En el caso particular de clasificación binaria, lo más común es utilizar la matriz de confusión junto con métricas como el *accuracy*, la sensibilidad, especificidad y el área bajo la curva ROC (AUC).

La matriz de confusión consiste en una tabla de contingencia de dimensión  $2 \times 2$ , en la que las columnas representan las clases reales y las filas corresponden a las clases predichas. Para construirla, es necesario establecer un umbral de decisión que permita transformar las probabilidades estimadas de pertenencia a la clase positiva en predicciones binarias. De este modo, se etiqueta cada instancia como indica la tabla 2.1.

Observación	Predicción	
	Positivos	Negativos
Positivos	Verdaderos Positivos (VP)	Falsos Negativos (FN)
Negativos	Falsos Positivos (FP)	Verdaderos Negativos (VN)

Tabla 2.1: Matriz de Confusión.

Esta tabla permite calcular métricas de rendimiento para el umbral seleccionado, como la especificidad (tasa de verdaderos negativos), sensibilidad (tasa de verdaderos positivos), y exactitud, dadas por las siguientes expresiones:

$$\text{Especificidad} = \frac{VN}{VN+FP}, \quad \text{Sensibilidad} = \frac{VP}{VP+FN}, \quad \text{Exactitud} = \frac{VP+VN}{VP+VN+FP+FN}.$$

Por otro lado, la curva ROC (*Receiver Operating Characteristics*) es una herramienta gráfica que permite visualizar la eficiencia de un modelo de clasificación binaria. Se trata de una gráfica bidimensional  $(0, 1) \times (0, 1)$ , en cuyo eje Y se representa la sensibilidad y en el eje X, la tasa de falsos positivos, es decir,  $1 - \text{especificidad}$ . Para la construcción de dicha curva, se ordenan todas las observaciones de mayor a menor según las probabilidades estimadas por el modelo. A continuación, se toma cada uno de estos valores como umbral de decisión para calcular el correspondiente par de valores ( $1 - \text{especificidad}$ , sensibilidad), que es representado en la gráfica. Así, conectando cada uno de estos puntos, se obtiene la curva ROC.

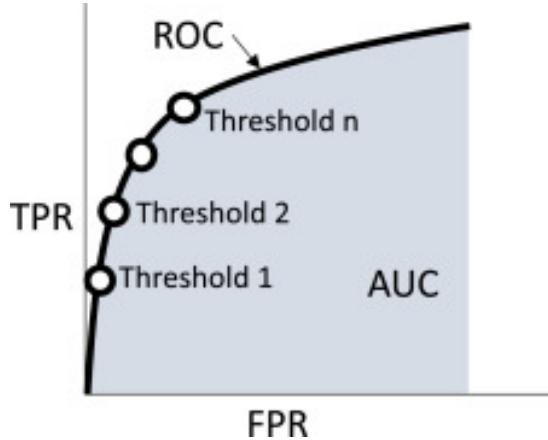


Figura 2.1: Construcción de la curva ROC (Ochoa-Estopier et al., 2023). Los términos originalmente en inglés representan: FPR (*false positive rate*, (1 – especificidad), TPR (*true positive rate*, sensibilidad) y *threshold* (umbral de decisión).

Notar que, de esta forma, el punto  $(0, 1)$  representa que ha sido clasificado de forma perfecta, es decir, sensibilidad máxima sin falsos positivos. En consecuencia, un modelo con una precisión total tendría todas sus observaciones en dicho punto, obteniendo así una curva que asciende verticalmente desde el  $(0, 0)$  y que continúa horizontalmente hasta el  $(1, 1)$ . Por el contrario, si todos sus puntos se alinean a lo largo de la diagonal, el modelo se comporta como un clasificador aleatorio. Ambos casos se pueden visualizar en la figura 2.2.

Para cuantificar el rendimiento global del modelo, se emplea el área bajo la curva ROC, conocido como AUC. Dado que la curva se encuentra contenida en el cuadrado  $(0, 1) \times (0, 1)$ , su valor oscila entre 0 y 1. Un valor de 1 indica una capacidad clasificatoria perfecta, mientras que un valor de 0,5 corresponde a un modelo sin poder predictivo. En caso de ser inferior a 0,5, se interpreta como una posible inversión a la hora de clasificar. De este modo, el AUC es equivalente a la probabilidad de que el correspondiente modelo categorize correctamente la clase postiva (Fawcett, 2006).

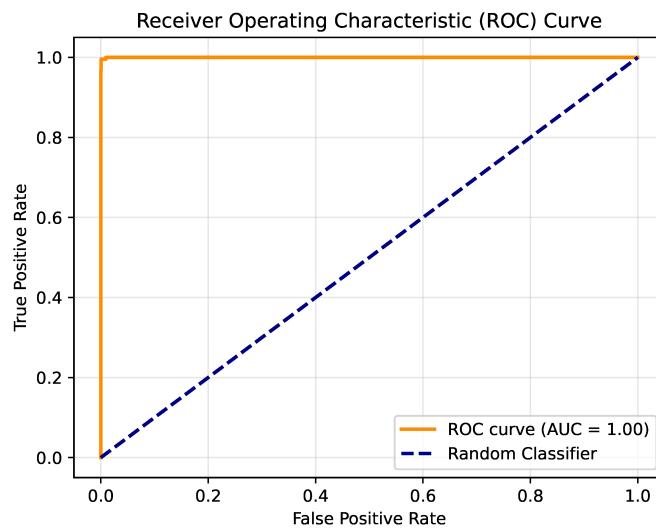


Figura 2.2: Ejemplo de curvas ROC (Zhang et al., 2025). Los términos originalmente en inglés representan: *False positive rate*, (1 – especificidad), *true positive rate*, sensibilidad) y *random classifier* (clasificador aleatorio).

## 2.8. Código empleado

Todo el análisis estadístico de este trabajo ha sido desarrollado en el lenguaje de programación R. El código completo se encuentra disponible en un repositorio público de GitHub, que se puede consultar en el siguiente enlace: [https://github.com/samuelggt/Samuel\\_Garcia\\_Garcia\\_Codigo\\_TFG](https://github.com/samuelggt/Samuel_Garcia_Garcia_Codigo_TFG).

En él, se incluyen tres archivos .R correspondientes a las principales fases del estudio. En todos ellos, la construcción y evaluación de los modelos se realiza empleando LOOCV.

El archivo "Modelo Variables Electrodiagnósticas.R" contiene el código para el diseño y análisis de un modelo de regresión logística basado en las cinco variables electrodiagnósticas.

El archivo "Modelos Lasso Variables US.R" incluye el código para la construcción de tres modelos Lasso con variables de ultrasonido cuantitativo (transversales, longitudinales y la combinación de ambas). También se desarrollan modelos de regresión logística clásicos utilizando como predictores las variables seleccionadas por Lasso.

El archivo "Modelos Red Elástica Variables US.R" contiene el código destinado al cálculo del AUC de los modelos ecográficos empleando red elástica con las diferentes técnicas de muestreo.

# Capítulo 3

## Resultados

Con el objetivo de evaluar el rendimiento predictivo de las variables ecográficas, se desarrollaron distintos modelos estadísticos. Todos ellos se entrenaron y validaron utilizando validación cruzada *leave-one-out* (LOOCV), con el fin de mitigar el impacto causado por disponer de una muestra con un escaso número de observaciones, pues se trata de un estudio piloto. En este procedimiento, se excluye un paciente y se construyen tantos modelos como observaciones de la muestra, entrenado cada uno de ellos con las  $n - 1$  observaciones restantes. Por tanto, en cada iteración de la validación cruzada, se almacenaron los coeficientes del respectivo modelo en una matriz  $n \times (p + 1)$ , cuyas filas representan al paciente excluido y, sus columnas, las diversas variables del modelo, incluyendo el intercepto. Adicionalmente, se obtuvo la probabilidad estimada por el modelo de que dicho paciente presente el síndrome del túnel carpiano, cuyo valor se guardó en la correspondiente coordenada de un vector. De esta forma, se evaluó el rendimiento evitando fenómenos de sobreajuste.

En primer lugar, se diseñó un modelo de regresión logística basado exclusivamente en las cinco variables de electrodiagnóstico. Posteriormente, se construyeron diferentes modelos Lasso: uno que incluye todas las variables ecográficas disponibles y dos modelos específicos que consideraban únicamente las variables obtenidas por las imágenes transversales y longitudinales, respectivamente. Adicionalmente, para los modelos Lasso se seleccionaron aquellas variables que aparecieron en al menos el 70% de las iteraciones de la validación cruzada, con el fin de construir modelos clásicos de regresión logística. Por último, se exploró una generalización de estos modelos Lasso mediante regresión red elástica con diferentes métodos de muestreo.

Los resultados obtenidos se detallan a continuación.

### 3.1. Modelo electrodiagnóstico

Como punto de partida, se construyó un modelo de regresión logística que incluye como variables dependientes las cinco obtenidas mediante las pruebas de conducción nerviosa, como la latencia distal y la amplitud motoras o la velocidad de conducción sensitiva.

Como se ha mencionado anteriormente, se construyeron tantos modelos como observaciones del conjunto de datos y, para cada uno de ellos, se guardaron los coeficientes y valores z de cada variable. Calculando la media de estos últimos a lo largo de todas las iteraciones, se obtuvo que las variables más significativas son la latencia distal motora y la conducción sensitiva, con z valores de 2,2321 y -2,1671 respectivamente. En la tabla 3.1 se muestran los valores de los coeficientes y valores z y p de cada variable. Además, obtenemos una curva ROC con un área bajo la curva de 0,8979.

Variable	Coeficiente	Valor z	Valor p
DISTAL.MOTOR.LATENCY..APB	1,08686808	2,2321	0,02723541
MOTORAMPLITUDE	-0,34515373	-1,38627	0,169207
MEDIAN.MOTOR.VELOCITY	0,05629184	0,5633459	0,5753327
MEDIANSENSORYCONDUCTION	-0,26197201	-2,167109	0,03070005
SENSORYAMPLITUDE	-0,01521074	-0,4354188	0,651167

Tabla 3.1: Variables del modelo junto a sus coeficientes y valores z y p.

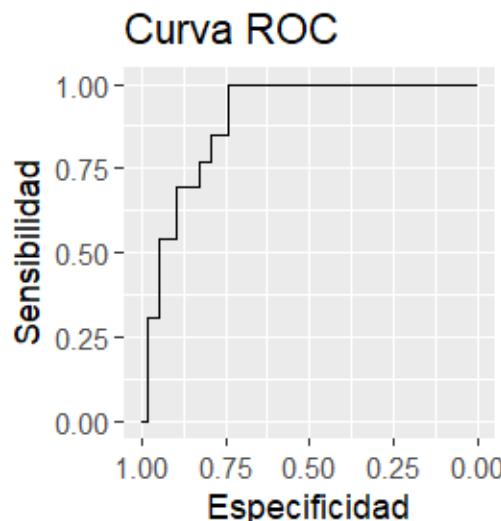


Figura 3.1: Curva ROC del modelo electrodiagnóstico, con AUC de 0,8979.

## 3.2. Modelos con variables ecográficas

El desarrollo de modelos predictivos basados en variables ecográficas presenta el inconveniente de su elevado número de predictores, pues son ochenta y ocho en total; prácticamente igual al número de observaciones. Para abordar este problema, se aplicó regresión Lasso, que permite incluir solo las variables más relevantes, dando un valor de cero a los coeficientes menos significativos.

En el proceso de realizar la validación cruzada leave-one-out, se diseñaron paralelamente modelos logísticos clásicos con las variables con coeficientes distintos de cero en Lasso. El objetivo de estos es que permiten calcular los valores z asociados a cada variable, que se almacenaron en su respectiva matriz, lo que proporciona una idea global de la significancia de cada una de ellas.

### 3.2.1. Modelo Completo

El modelo Lasso que incluye las ochenta y ocho variables de ultrasonido obtuvo un AUC de 0,588.

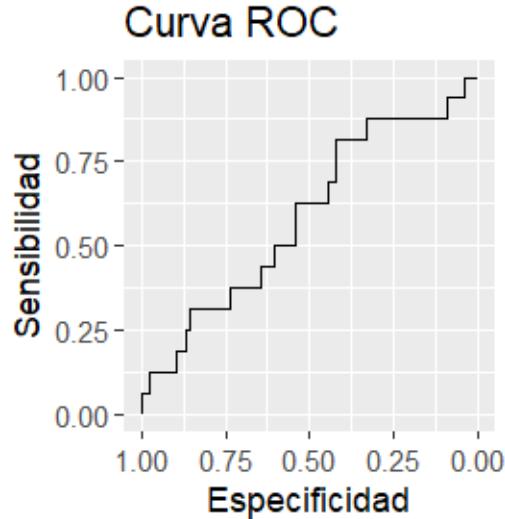


Figura 3.2: Curva ROC del modelo Lasso completo, con AUC de 0,588.

Se seleccionaron aquellas variables con coeficientes distintos de cero en, al menos, el 70 % de las iteraciones. A continuación, se muestra una tabla con dichas variables, junto a sus valores z promedio y la proporción de veces que fueron seleccionadas.

Variable	Valor z	Proporción
CT_GLCM_DVariance	1,231912	94,57 %
BST_GLDS_ASM	0,9172849	75 %
CL_GLDS_Homogeneity	1,334449	78,26 %

Tabla 3.2: Variables seleccionadas por el modelo Lasso completo.

Con estas tres variables se diseñó un modelo de regresión logística, del que se obtuvo una curva ROC con un AUC de 0,7508.

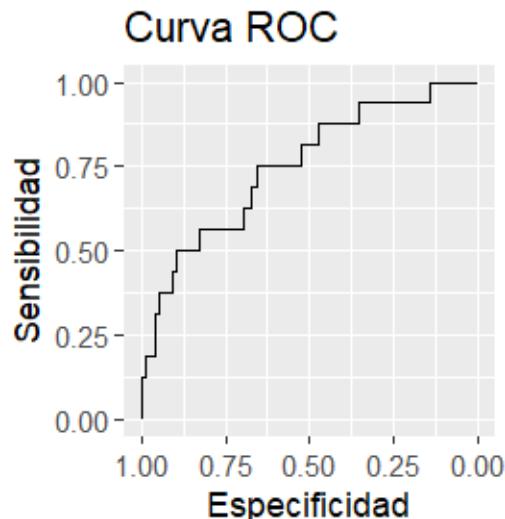


Figura 3.3: Curva ROC del modelo logístico completo, con AUC de 0,7508.

Variable	Coeficiente	Valor z	Valor p
CT_GLCM_DVariance	2127,594	2,0370161	0,04265219
BST_GLDS_ASM	$3,749548 \cdot 10^{-7}$	0,9382832	0,3500963
CL_GLDS_Homogeneity	0,001169353	2,0739959	0,03901780

Tabla 3.3: Variables del modelo logístico completo junto a sus coeficientes y valores z y p.

### 3.2.2. Modelo Transversal

De manera análoga, se desarrolló otro modelo Lasso empleando únicamente las cuarenta y cuatro variables obtenidas por las imágenes de las ecografías transversales. El AUC que se obtuvo en esta ocasión tiene un valor de 0,6275.

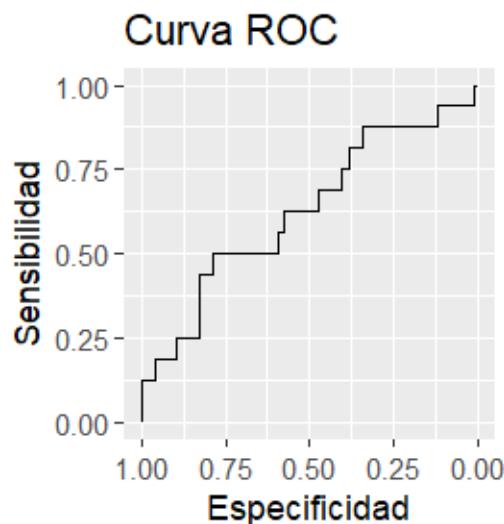


Figura 3.4: Curva ROC del modelo Lasso transversal, con AUC de 0,6275.

Las variables seleccionadas con su valor z medio y frecuencia fueron:

Variable	Valor z	Proporción
CT_GLCM_DVariance	2,025993	97.83 %
MT_Desvest	0,7299165	71.74 %
BST_GLDS_ASM	1,272369	96.74 %

Tabla 3.4: Variables seleccionadas por el modelo Lasso transversal.

El modelo logístico construido con estas tres variables obtuvo un AUC de 0,7344.

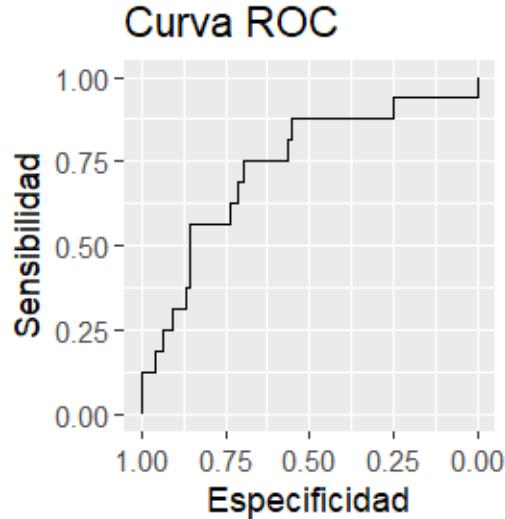


Figura 3.5: Curva ROC del modelo logístico transversal, con AUC de 0,7344.

Variable	Coeficiente	Valor z	Valor p
CT_GLCM_DVariance	$2,278535 \cdot 10^3$	2,2254915	0,02677348
MT_Desvest	5,040648	0,9402899	0,3501178
BST_GLDS_ASM	$4,579878 \cdot 10^{-7}$	1,1534666	0,2511253

Tabla 3.5: Variables del modelo logístico transversal junto a sus coeficientes y valores z y p.

### 3.2.3. Modelo Longitudinal

Finalmente, se diseñó un modelo Lasso con las variables correspondiente a las imágenes longitudinales, obteniendo un AUC de 0,6486.

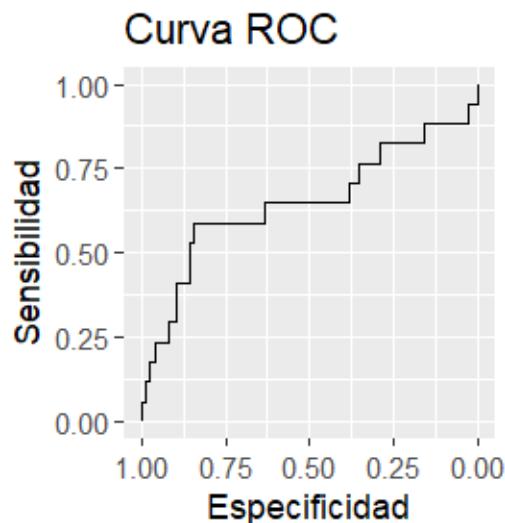


Figura 3.6: Curva ROC del modelo Lasso longitudinal, con AUC de 0,6486.

Las variables seleccionadas fueron:

Variable	Valor z	Proporción
CL_GLDS_Homogeneity	3,314561	100 %
CL_haar_mean	-2,310588	91.40 %
BIL_GLCM_DVariance	0,2041714	72.04 %
BIL_GLCM_Correlation	-1,729739	74.19 %

Tabla 3.6: Variables seleccionadas por el modelo Lasso longitudinal.

Dado su bajo valor z, se descartó la variable BIL\_GLCM\_DVariance para la construcción del modelo de regresión logística. El modelo ajustado con las tres variables restantes alcanzó un AUC de 0,8019.

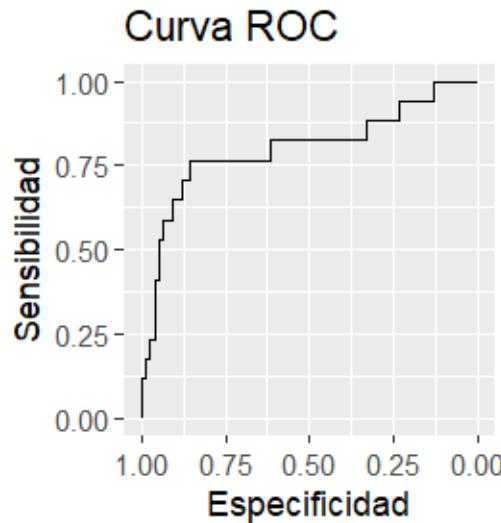


Figura 3.7: Curva ROC del modelo logístico longitudinal, con AUC de 0,8019.

Variable	Coeficiente	Valor z	Valor p
CL_GLDS_Homogeneity	$2,005533 \cdot 10^3$	3,513983	0,0004544207
CL_haar_mean	-0,056137674	-2,746450	0,0063406856
BIL_GLCM_Correlation	-50,660490458	-2,412677	0,0169192306

Tabla 3.7: Variables del modelo logístico longitudinal junto a sus coeficientes y valores z y p.

### 3.2.4. Modelos de red elástica

A pesar de ser modelos más complejos, la red elástica trabaja mejor la colinealidad y, al incluir también penalización en la norma dos de los coeficientes, se consigue mayor estabilidad. En particular, para modelos con un alto número de predictores, la red elástica tiene mejor rendimiento. Por tanto, es interesante generalizar los modelos Lasso anteriores a red elástica para verificar si se obtiene suficiente mejora que contrarreste su complejidad. Adicionalmente, puesto que se tiene un gran desequilibrio de clases, se construyeron los modelos utilizando distintos métodos de muestreo.

En la siguiente tabla se muestran los valores del área bajo la curva ROC en cada situación.

Método muestreo	AUC Completo	AUC transversal	AUC longitudinal
Ninguno	0.6867	0.5337	0.6966
Undersampling	0.7048	0.5806	0.6563
Oversampling	0.6554	0.5757	0.7384
Smote	0.7056	0.5411	0.6943
Rose	0.6867	0.5625	0.6699

Tabla 3.8: AUC red elástica para cada modelo y método de muestreo.

## Capítulo 4

# Discusión

El objetivo principal de este trabajo fue evaluar el rendimiento de ultrasonido cuantitativo proporcionado por *UZqTool* como herramienta predictiva en el diagnóstico del síndrome del túnel carpiano, comparándolo con el electrodiagnóstico convencional. Para ello, se aplicaron técnicas de regresión logística regularizadas mediante Lasso y red elástica, en combinación con validación cruzada *leave-one-out*, sobre una muestra clínica de 94 observaciones. Los resultados obtenidos muestran que el modelo electrodiagnóstico alcanzó un AUC de 0,8979, mientras que el mejor modelo basado en ecografía, construido a partir de variables extraídas de imágenes longitudinales seleccionadas mediante Lasso, obtuvo un AUC de 0,8019. Aunque este valor es inferior al del modelo de referencia, se trata de un modelo con una alta capacidad predictiva, lo que refuerza el potencial diagnóstico del ultrasonido cuantitativo.

El hecho de que el modelo basado en electrodiagnóstico no alcance un AUC perfecto, es decir, de 1.0, indica que, a pesar de su elevada precisión, la prueba no capta por completo la complejidad clínica del STC. Las pruebas ECN realizadas, EMG y VCN, registran señales eléctricas objetivas, pero no tienen en cuenta aspectos clínicos importantes. Factores como la variabilidad subjetiva del dolor, el umbral de percepción individual, la cronicidad de los síntomas o la capacidad del sistema nervioso para compensar parcialmente la comprensión pueden influir en el diagnóstico sin alterar necesariamente los valores diagnósticos. Este fenómeno puede dar lugar a discrepancias entre el diagnóstico clínico y los resultados de los ECN, lo que implica que el modelo no siempre identifique correctamente los verdaderos positivos o negativos, pues depende de la situación particular de cada paciente. Si bien es cierto que un AUC de 0,8979 es extremadamente elevado y se puede asumir que el modelo es efectivo a la hora de predecir la patología, la complejidad clínica del STC provoca que su diagnóstico no sea completamente preciso mediante una sola prueba.

En contraste, las pruebas ecográficas reflejan el estado estructural del nervio, como su forma, textura o grosor, en lugar de su funcionamiento, lo que ofrece un enfoque diferente al electrodiagnóstico. Sin embargo, este estudio conlleva una serie de problemas: su elevado número de predictores y una muestra de pacientes limitada, lo que aumenta el riesgo de sobreajuste y colinealidad entre variables. El uso de la regresión Lasso permitió afrontar estas limitaciones, pues diseña modelos con las variables más informativas, siendo también utilizado como método de selección de características. En cuanto a los resultados concretos, los modelos derivados de variables obtenidas mediante la ecografía transversal y longitudinal mostraron diferencias sustanciales. Si bien los modelos Lasso obtuvieron AUC considerablemente bajos, con valores entre 0,588 y 0,6486, tras seleccionar las características más relevantes de cada uno y desarrollar nuevos modelos logísticos con dichas variables, estos mejoraron a los anteriores. El modelo que combina todas las variables alcanzó un AUC de 0,7508, el modelo transversal obtuvo 0,7344, mientras que el modelo longitudinal alcanzó el mejor rendimiento con 0,8019. Esta diferencia sugiere que las imágenes longitudinales captan mejor la morfología global del nervio y sus posibles alteraciones estructurales. Esta observación podría tener implicaciones prácticas para la estandarización de protocolos ecográficos orientados al diagnóstico del STC.

Por otro lado, la aplicación de la red elástica como alternativa más compleja no mejoró suficientemente los resultados. A pesar de incorporar penalización a ambas normas de los coeficientes, lo que

teóricamente ofrece mayor estabilidad frente a la colinealidad, sus resultados fueron similares o incluso peores que los obtenidos con Lasso, especialmente en el caso longitudinal, donde su AUC osciló entre 0,6563 y 0,7384, dependiendo el método de muestreo, sin superar en ningún caso el 0,8019. Esta falta de mejora puede deberse a la simplicidad efectiva del modelo tras la selección de variables, lo cual limita los beneficios que aporta la regularización en la norma dos. Además, como se tiene una muestra especialmente pequeña, el aumento de complejidad podría haber supuesto una mayor variabilidad.

En comparación con el estudio previo de validación de la herramienta *UZqTool* (Albarova-Corral et al., 2024), que obtuvo un AUC de 0,75 en el diagnóstico de lesiones del tendón rotuliano, el modelo longitudinal hallado en este trabajo presenta una mejora evidente. Esta puede deberse a una combinación de factores: una muestra más amplia, de noventa y cuatro observaciones frente a catorce; el uso de validación LOOCV, que mejora especialmente los modelos en contextos de muestras pequeñas; y la selección rigurosa de variables mediante Lasso, que ya se ha visto que dicha simplicidad de los modelos contribuye a un mayor rendimiento. Además, mientras el estudio anterior se limitaba a una única perspectiva ecográfica, en este trabajo se exploran y comparan imágenes longitudinales y transversales del nervio mediano, lo que amplía el análisis y mejora la capacidad predictiva.

Al relacionar directamente el modelo ecográfico longitudinal con el modelo de referencia basado en electrodiagnóstico, se observa que, si bien existe diferencia en el rendimiento, esta no es excesiva; el modelo longitudinal presenta una capacidad predictiva elevada. Esta cercanía en los valores AUC nos permite destacar las implicaciones clínicas de estos hallazgos. El ultrasonido cuantitativo ofrece una alternativa no invasiva, accesible y más económica al electrodiagnóstico, lo que podría facilitar el diagnóstico del STC. Aunque los resultados obtenidos no muestran que se pueda sustituir por completo el estándar actual, el desarrollo y perfeccionamiento de esta herramienta podrían posicionarla como un instrumento diagnóstico clave en los próximos años. Estos hallazgos abren la puerta a futuras investigaciones con muestras más amplias, evaluación multicéntrica y validación externa, pasos fundamentales para consolidar el ultrasonido cuantitativo en la práctica clínica.

# Bibliografía

- Fawcett, T. (2006). Introduction to ROC analysis. *Pattern Recognition Letters*, 27, 861-874. <https://doi.org/10.1016/j.patrec.2005.10.010>
- Hastie, T., Tibshirani, R., Friedman, J. H., & Friedman, J. H. (2009). *The elements of statistical learning: data mining, inference, and prediction* (Vol. 2). Springer.
- Kleinbaum, D., & Klein, M. (2010). *Logistic Regression: A Self-Learning Text*. Springer New York.
- Menardi, G., & Torelli, N. (2012). Training and assessing classification rules with unbalanced data. *Data Mining and Knowledge Discovery*. <https://doi.org/10.1007/s10618-012-0295-5>
- Galecki, A., & Burzykowski, T. (2013). *Linear Mixed-Effects Models Using R: A Step-by-Step Approach*. Springer.
- Weiss, G. M. (2013). Foundations of Imbalanced Learning. En *Imbalanced Learning* (pp. 13-41). John Wiley Sons, Ltd. <https://doi.org/https://doi.org/10.1002/9781118646106.ch2>
- Lunardon, N., Menardi, G., & Torelli, N. (2014). ROSE: a Package for Binary Imbalanced Learning. *R Journal*, 6, 79-89. <https://doi.org/10.32614/RJ-2014-008>
- Chen, Y.-T., Miller Olson, E. K., Lee, S.-h., Sainani, K., & Fredericson, M. (2021). Assessing Diagnostic and Severity Grading Accuracy of Ultrasound Measurements for Carpal Tunnel Syndrome Compared to Electrodiagnostics. *PM&R*, 13(8), 852-861.
- Kim, S. W., Kim, S., Shin, D., Choi, J. H., Sim, J. S., Baek, S., & Yoon, J. S. (2023). Feasibility of artificial intelligence assisted quantitative muscle ultrasound in carpal tunnel syndrome. *BMC Musculoskeletal Disorders*, 24(1), 524.
- MedlinePlus. (2023a). *Síndrome del túnel carpiano*. U.S. National Library of Medicine. <https://medlineplus.gov/spanish/ency/article/000433.htm>
- MedlinePlus. (2023b). *Velocidad de conducción nerviosa*. U.S. National Library of Medicine. <https://medlineplus.gov/spanish/ency/article/003927.htm>
- Ochoa-Estopier, L. M., Gourvénec, S., Cahors, R., Behara, N., & Scellier, J.-B. (2023). Prediction of flooding in distillation columns using machine learning. *Digital Chemical Engineering*, 7, 100098. <https://doi.org/https://doi.org/10.1016/j.dche.2023.100098>
- Albarova-Corral, I., Segovia-Burillo, J., Malo-Urriés, M., Ríos-Asín, I., Asín, J., Castillo-Mateo, J., Gracia-Tabuenca, Z., & Morales-Hernández, M. (2024). A new quantitative tool for the ultrasonographic assessment of tendons: a reliability and validity study on the patellar tendon. *Diagnostics*, 14(11), 1067. <https://doi.org/10.3390/diagnostics14111067>
- Cleophas, T. J., & Zwinderman, A. H. (2024). *Application of Regularized Regressions to Identify Novel Predictors in Clinical Research*. Springer.
- Junior, G. P. A., & Pereira, G. H. A. (2024). A comparison of the discrimination performance of lasso and maximum likelihood estimation in logistic regression model. <https://arxiv.org/abs/2404.17482>
- MedlinePlus. (2024a). *Ecografía*. U.S. National Library of Medicine. <https://medlineplus.gov/spanish/pruebas-de-laboratorio/ecografia/>
- MedlinePlus. (2024b). *Electromiografía*. U.S. National Library of Medicine. <https://medlineplus.gov/spanish/ency/article/003929.htm>
- Zhang, Z., Chen, T., & Todo, Y. (2025). Concatenated Attention: A Novel Method for Regulating Information Structure Based on Sensors. *Applied Sciences*, 15(2). <https://doi.org/10.3390/app15020523>

# Apéndice

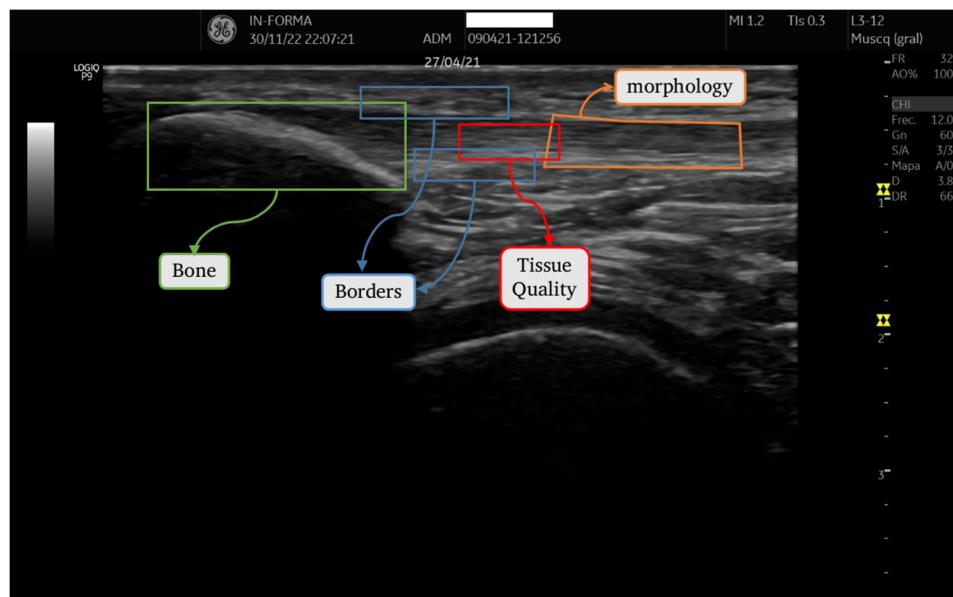


Figura 4.1: Selección de las regiones de interés en el caso del nervio rotuliano, incluyendo la calidad del tejido (*tissue quality*, en rojo), los bordes inferior y superior (*borders*, en azul), y el grosor (*morphology*, en naranja). Se incluye también la región correspondiente a la inserción con el hueso (*bone*, en verde), no presente en las imágenes del tendón carpiano (Albarova-Corral et al., [2024](#)).

<b>Tissue Quality and Superior/Inferior Borders</b>	<b>Morphology</b>
<ul style="list-style-type: none"> <li>• GLCM Matrix Contrast</li> <li>• GLCM Sum Average</li> <li>• GLCM Sum-of-Squares Variance</li> <li>• GLCM Difference Variance</li> <li>• GLCM Correlation</li> <li>• GLCM Inverse Difference Moment</li> <li>• GLDS Homogeneity</li> <li>• GLDS Contrast</li> <li>• GLDS Angular Second Moment</li> <li>• GLDS Entropy</li> <li>• GLDS Mean</li> <li>• Haar Mean</li> <li>• Haar Variance</li> </ul>	<ul style="list-style-type: none"> <li>• Max Width</li> <li>• Min Width</li> <li>• Mean Width</li> <li>• Standard Deviation (Parallelism)</li> <li>• Ratio between Max and Min Width</li> </ul>

Tabla 4.1: Lista de variables ecográficas para las cuatro regiones de interés: *Tissue Quality* (calidad del tejido), *superior and inferior borders* (bordes superior e inferior) y *morphology* (grosor del tendón).